EXPLAINMAINT | Classification explicable

ENSI - Data Mining - Challenge 1 - Maintenance predictive industrielle (cas 15)

1 | Problematique et donnees

AI4I 2020 (UCI, ID 601), jeu synthetique. 10 000 observations a l origine. Cible : panne machine (1) contre fonctionnement (0). Six facteurs : type, temperatures, vitesse, couple et usure. TWF/HDF/PWF/OSF/RNF et identifiants exclus pour eviter la fuite de cible.

Observations utilisees : **10000** | Taux de classe positive : **a mesurer a l execution**. Decoupage aleatoire stratifie, graine 42, preprocessing ajuste sur apprentissage seul.

2 | Modeles, evaluation et choix

Regression logistique, arbre, KNN, Random Forest, XGBoost. AUC-ROC, AP (PR-AUC), precision, rappel et F1 ; choix du seuil selon le cout des pannes non detectees et des fausses alertes.

Statut des mesures	Non exécutées dans cette livraison statique
AUC, AP, P, R, F1	À renseigner après entraînement dans l’application
Seuil de décision	À définir dans le module Évaluation

3 | Explicabilite et actions

Examiner les importances natives et par permutation, le SHAP beeswarm / dependance, puis SHAP waterfall et LIME sur le meme individu. Les facteurs dominants sont a relever sur la sortie calculee ; aucune importance numerique n est supposee avant execution.

Decision : prioriser les inspections des cas classes a fort risque et controler physiquement l usure, le couple, la rotation et l ecart thermique ; fixer le seuil en concertation avec la maintenance.

4 | Analyse critique et limites

SHAP et LIME decrivent le modele, pas une causalite ni un diagnostic mecanique certain. Confronter les signes aux connaissances terrain et documenter leurs divergences. Les variables UCI retenues ne comportent pas de donnees personnelles directement sensibles ; un CSV externe exige une analyse d equite (age, sexe, etc.). XGBoost peut mieux capter des interactions ; une regression logistique reste plus directement lisible : recommander selon AP, rappel et contraintes de gouvernance, pas sur le nom de l algorithme. Le dataset est synthetique : pas de validation chronologique ni de preuve de performance en production.

Source : UCI Machine Learning Repository, AI4I 2020 Predictive Maintenance Dataset, DOI 10.24432/C5HS5C (CC BY 4.0).
Resultats chiffres uniquement si issus de l execution.